



Universidade Estadual de Campinas
Faculdade de Tecnologia

PROJETO DE PESQUISA

BUSCA AUTOMÁTICA E CLASSIFICAÇÃO SEMÂNTICA DE DOCUMENTOS DE
CONCEPÇÃO DE SISTEMAS CRÍTICOS PARA UTILIZAÇÃO NO PROCESSO STPA

Candidato: Arthur Miele Malveste
Orientador: Profa. Dra. Ana Estela Antunes da Silva
Coorientador: Prof. Dr. Pedro Ivo Garcia Nunes

Limeira
2026



Resumo

Sistemas Críticos demandam abordagens rigorosas de análise de perigos, a exemplo da técnica *System-Theoretic Process Analysis* (STPA). Contudo, a aplicação da STPA nas fases iniciais de concepção de um sistema enfrenta um gargalo operacional: a triagem predominantemente manual de extensas bases de documentos não estruturados, como os de *Concept of Operations* (ConOps). Nesse contexto, o projeto de Iniciação Científica tem como objetivo desenvolver um *pipeline* automatizado para a coleta, extração e classificação semântica de documentos técnicos de concepção. A metodologia estrutura-se, inicialmente, em rotinas de *Web Crawling* para extração de arquivos em repositórios institucionais, a exemplo da *National Aeronautics and Space Administration* (NASA) e da *European Space Agency* (ESA). Em seguida, realiza-se a extração textual e a representação semântica desses dados utilizando modelos de arquitetura *Transformer*, como o BERT. O escopo principal da etapa de classificação consistirá na aplicação de Modelos de Linguagem de Grande Escala (LLMs), averiguando sua eficácia técnica na análise direta e validação semântica dos documentos ConOps. Como resultado, espera-se a criação de uma base de documentos classificados e estruturados, mitigar o tempo e custo das equipes de segurança e apoiar diretamente o macroprojeto de automação da STPA desenvolvido em parceria com a indústria aeronáutica.

Palavras-chave: STPA; Processamento de Linguagem Natural; *Web Crawling*; LLM; Sistemas Críticos.

1 Introdução

A presença de Sistemas Críticos (SC) tem se expandido exponencialmente nas sociedades modernas, englobando desde infraestruturas aeroespaciais e de aviação até equipamentos médicos e veículos autônomos. Devido à alta complexidade e ao acoplamento desses sistemas, as abordagens tradicionais de análise de confiabilidade (focadas apenas na falha de componentes físicos) têm se mostrado insuficientes para prevenir acidentes sistêmicos (LEVESON, 2011). Nesse cenário, destaca-se a *System-Theoretic Process Analysis* (STPA), uma técnica de análise de perigos



fundamentada na teoria de controle, que compreende a segurança como um problema de controle inadequado entre os componentes do sistema.

Apesar de sua eficácia comprovada e ampla adoção na indústria aeronáutica, a aplicação da STPA nas fases iniciais de concepção de um sistema enfrenta um gargalo operacional significativo. A etapa inicial da técnica exige a identificação minuciosa de perdas, perigos e restrições de segurança a partir de extensas bases de documentos técnicos não estruturados, com destaque para os documentos de *Concept of Operations* (ConOps). Atualmente, a busca, triagem e classificação desses documentos em repositórios públicos e institucionais — como a *National Aeronautics and Space Administration* (NASA), a *European Space Agency* (ESA) e o Departamento de Defesa dos EUA — são processos realizados de forma predominantemente manual. Isso torna a análise custosa, lenta e suscetível à fadiga e ao erro humano.

Diante dessa lacuna tecnológica, o projeto de Iniciação Científica propõe o desenvolvimento de uma abordagem automatizada que combina técnicas de Recuperação de Informação (*Web Crawling* semântico) e Processamento de Linguagem Natural (PLN) para localizar e extrair documentos ConOps relevantes. O avanço científico central da proposta reside na aplicação de Inteligência Artificial Generativa, especificamente Modelos de Linguagem de Grande Escala (LLM), para realizar a classificação semântica direta desses documentos, automatizando a distinção entre arquivos pertinentes à concepção do sistema e documentos genéricos.

A justificativa para a realização desta pesquisa ampara-se no potencial prático e industrial da automação do *pipeline* de recuperação de documentos (que se propõe a ser denominado *ConOps Document Retrieval Pipeline*). Esta automação oferece escalabilidade, permitindo reduzir drasticamente o tempo e o custo das equipes de engenharia de segurança de software.

No âmbito acadêmico e institucional, este projeto fornece suporte computacional ao projeto de pesquisa intitulado "Automação da STPA utilizando Processamento de Linguagem Natural e Aprendizado de Máquina" (MARTINS et al., 2025), financiado pela



Fundação de Amparo à Pesquisa do Estado de São Paulo (FAPESP) e desenvolvido pela Universidade Estadual de Campinas (UNICAMP) em cooperação direta com a Embraer e o *Blekinge Institute of Technology* (Suécia). Dessa forma, a pesquisa garante não apenas relevância teórica, mas aplicabilidade imediata em um contexto industrial.

2 Objetivos

O objetivo geral deste trabalho é desenvolver um *pipeline* automatizado para a coleta, extração e classificação semântica de documentos técnicos de concepção de sistemas ConOps, utilizando técnicas de PLN e Inteligência Artificial Generativa, com o intuito de gerar uma base de documentos de especificação de conceitos de sistemas críticos e a classificação desses documentos por meio de um modelo classificador.

Para o alcance do objetivo geral, estabelecem-se os seguintes objetivos específicos:

- **Implementar rotinas de *Web Crawling*:** Construir algoritmos automatizados para a navegação e coleta de arquivos documentais em repositórios técnicos e institucionais de domínio aeroespacial e de defesa.
- **Realizar extração e pré-processamento textual:** Desenvolver rotinas para extrair o texto bruto dos documentos coletados e aplicar filtros de limpeza baseados em léxico específico do domínio de sistemas críticos.
- **Gerar representações semânticas:** Empregar modelos de Processamento de Linguagem Natural baseados em arquitetura *Transformer* para converter os textos filtrados em representações vetoriais (*embeddings*), capturando o contexto semântico dos documentos.ESA
- **Desenvolver o módulo de classificação principal via LLM:** Estruturar e avaliar a eficácia de LLM na análise direta e classificação binária dos documentos coletados, atestando sua aderência ao padrão ConOps.

3 Metodologia



A presente pesquisa caracteriza-se como um estudo de natureza aplicada e exploratória, com abordagem quantitativa e qualitativa no tratamento de dados textuais. O desenvolvimento metodológico será estruturado em torno da construção e validação de um *pipeline* automatizado de recuperação e análise de documentos técnicos.

A execução do projeto é dividida em cinco etapas sequenciais e interdependentes:

Etapas 1: Coleta Automática de Dados (*Web Crawling*) A fase inicial consistirá no desenvolvimento de *scripts* automatizados (robôs de busca) para localizar e realizar o *download* de documentos técnicos em formato *Portable Document Format* (PDF). O foco da coleta abrangerá repositórios de organizações do setor aeroespacial e de defesa, tais como a NASA, a ESA e o *United States Department of Defense* (DoD). Para a implementação dos *crawlers*, serão avaliadas bibliotecas da linguagem Python, como *Scrapy*, *BeautifulSoup* e *Selenium*, parametrizadas com *strings* de busca direcionadas (MITCHELL, 2018).

Etapas 2: Extração de Texto e Pré-processamento Após a aquisição do acervo em PDF, o sistema realizará a conversão e extração computacional do texto bruto. Devido à complexidade de formatação de manuais de engenharia, serão utilizadas ferramentas especializadas em *parsing* documental (a exemplo do *PDFMiner* ou *Apache Tika*). O texto extraído passará por rotinas de limpeza via Expressões Regulares (*Regex*) para remoção de ruídos de formatação.

Etapas 3: Filtragem Baseada em Palavras-chave Para garantir a viabilidade computacional das etapas subsequentes, será aplicada uma filtragem inicial voltada à eliminação de documentos não relacionados ao escopo do projeto. Será utilizado um dicionário léxico contendo termos intrínsecos ao domínio de concepção, tais como *Mission Concept*, *Operational Scenario* e *System Operational Description*.

Etapas 4: Representação Semântica (*Embeddings*) Os documentos aprovados na triagem inicial serão convertidos em vetores matemáticos de alta dimensionalidade (*embeddings* semânticos). Esta etapa fará uso de modelos de PLN baseados na



arquitetura *Transformer* (VASWANI et al., 2017), com destaque para a implementação de algoritmos da família *Bidirectional Encoder Representations from Transformers* (DEVLIN et al., 2019).

Etapas 5: Classificação Automática Semântica Nesta etapa central e final do *pipeline*, o sistema classificará a pertinência do documento ao padrão ConOps. A estratégia consistirá na aplicação de LLM, a exemplo do GPT-4 (OPENAI, 2023) ou LLaMA (TOUVRON et al., 2023). Esses modelos analisarão os textos por meio de técnicas de *Prompt Engineering* (BROWN et al., 2020), utilizando instruções diretas e estruturadas para realizar a validação semântica da base de dados e entregar um acervo classificado e limpo para o processo STPA.

4 Cronograma de Execução

As atividades propostas para esta Iniciação Científica serão desenvolvidas ao longo de meses (de setembro de 2026 a agosto de 2027), divididas nas seguintes etapas estruturais:

- **Atividade 1:** Levantamento bibliográfico sistemático, estudo das ferramentas e definição da arquitetura do *pipeline*.
- **Atividade 2:** Implementação das rotinas de *Web Crawling* e coleta do acervo documental em formato PDF.
- **Atividade 3:** Extração computacional do texto bruto, limpeza de ruídos de formatação (*Regex*) e filtragem por palavras-chave.
- **Atividade 4:** Aplicação de modelos *Transformer* (BERT) para geração de representações semânticas e entrega do Relatório Parcial.
- **Atividade 5:** Desenvolvimento, estruturação de *prompts* e validação da classificação automática semântica utilizando LLM.
- **Atividade 6:** Consolidação dos resultados, validação da base de documentos estruturada, redação de artigo científico, entrega do Relatório Final e apresentação no Congresso.



A distribuição temporal destas atividades está disposta no Quadro 1

Quadro 1 - Cronograma de atividades

Atividades	2026				2027							
	Set	Out	Nov	Dez	Jan	Fev	Mar	Abr	Mai	Jun	Jul	Ago
1	X											
2		X	X									
3				X	X	X						
4						X	X	X				
5									X	X		
6											X	X

Referências Bibliográficas

BROWN, T. B. et al. Language Models are Few-Shot Learners. In: **Advances in Neural Information Processing Systems**, v. 33, p. 1877-1901, 2020.

DEVLIN, J.; CHANG, M. W.; LEE, K.; TOUTANOVA, K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In: **Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies**, v. 1, p. 4171-4186, 2019.

LEVESON, N. G. **Engineering a Safer World: Systems Thinking Applied to Safety**. Cambridge, MA: MIT Press, 2011.

MARTINS, L. E. G. et al. Automação da STPA Utilizando Processamento de Linguagem Natural e Aprendizado de Máquina. **Projeto de Pesquisa - Fundação de Amparo à**



Pesquisa do Estado de São Paulo (FAPESP). Campinas: Universidade Estadual de Campinas, 2025.

MITCHELL, R. **Web Scraping with Python: Collecting More Data from the Modern Web.** 2. ed. Sebastopol: O'Reilly Media, 2018.

OPENAI. **GPT-4 Technical Report.** arXiv preprint arXiv:2303.08774, 2023. Disponível em: <https://arxiv.org/abs/2303.08774>. Acesso em: 28 mar. 2026.

TOUVRON, H. et al. LLaMA: Open and Efficient Foundation Language Models. **arXiv preprint arXiv:2302.13971**, 2023. Disponível em: <https://arxiv.org/abs/2302.13971>. Acesso em: 28 mar. 2026.

VASWANI, A. et al. Attention is all you need. In: **Advances in Neural Information Processing Systems**, p. 5998-6008, 2017.