Etapa 2 — Extração de Texto dos Documentos de Concepção

Relatório de andamento da Iniciação Científica *Busca Automática e Classificação Semântica de Documentos de Concepção de Sistemas Críticos para Utilização no Processo STPA* — Arthur Miele Malveste · FT/UNICAMP · outubro de 2026

1. O que é esta etapa

O projeto de IC organiza o trabalho em cinco etapas sequenciais: (1) coleta de documentos por *web crawling*; (2) extração de texto e pré-processamento; (3) filtragem por palavras-chave do domínio; (4) representação semântica com *embeddings*; (5) classificação automática com LLM. Este relatório descreve a **Etapa 2**: transformar os arquivos baixados na Etapa 1 — em sua maioria PDFs de NASA, FAA, Departamento de Transportes dos EUA (ROSA P) e governo britânico — em texto limpo, com a estrutura de seções preservada, pronto para a Etapa 3.

A etapa **não julga** se um documento é ou não um ConOps: ela só garante que o conteúdo de cada arquivo esteja disponível como texto legível. Essa decisão pertence à Etapa 5.

2. Ponto de partida: o corpus coletado

Ao início da etapa o corpus tinha **43 PDFs de outras fontes**, **152 PDFs do NTRS** (NASA) e **65 documentos do NTRS disponíveis só como texto** — o NTRS oferece, além do PDF, um arquivo .txt extraído pela própria NASA. A tabela resume o que esta etapa processou.

Fonte	PDFs	Páginas	Observação
rosap	31	1636	Repositório do Dep. de Transportes dos EUA
faa	5	260	Federal Aviation Administration
govuk	5	209	Documentos de conceito operacional do governo britânico
rosap_crawl	2	212	ROSA P via navegação (crawl)
ntrs (.txt)	65	—	Texto da NASA, usado como está (só limpeza)
ntrs (PDF)	152	3829	Fora desta rodada — decisão pendente (seção 5.3)

Quase todos os PDFs já têm camada de texto digital (gerados por Word/Adobe ou já passados por OCR pela NASA). Isso foi verificado antes de escolher a configuração da ferramenta e mudou a decisão sobre OCR (seção 5.1).

3. Ferramenta escolhida: Docling

O projeto original da IC citava PDFMiner ou Apache Tika seguidos de expressões regulares. Antes de implementar, foi feita uma pesquisa das ferramentas mais usadas hoje para extrair texto de documentos técnicos, considerando três requisitos do nosso caso: (a) **preservar a estrutura de seções**, porque a Etapa 3 procura termos como *Operational Scenarios* dentro das seções; (b) lidar com tabelas e papers em duas colunas, comuns nos ConOps; (c) rodar em um computador pessoal, sem GPU, com licença aberta.

Ferramenta	Tipo	Estrutura (seções/tabelas)	Por que não / por que sim
PDFMiner.six, pypdf	Extração direta	Não	Rápidas, mas texto corrido sem estrutura; PDFMiner é o mais lento nos benchmarks
Apache Tika	Extrator genérico (Java)	Não	Exige Java; mesma limitação estrutural

Ferramenta	Tipo	Estrutura (seções/tabelas)	Por que não / por que sim
PyMuPDF	Extração direta	Parcial	Muito rápido, mas licença AGPL e sem títulos de seção
GROBID	Artigos científicos	Sim, para artigos	Modelado para papers, não relatórios técnicos longos
MinerU, Marker	Análise de layout por IA	Sim	Pesados (GPU) e com restrições de licença nos modelos
Docling (IBM)	**Análise de layout por IA**	**Sim**	**Licença MIT, roda em CPU, gera Markdown com títulos e tabelas, OCR embutido opcional**

O Docling foi escolhido por equilibrar os três requisitos. A saída é Markdown: os títulos de seção viram linhas ## 2.3 Operational Scenarios e as tabelas viram tabelas legíveis — exatamente a informação de que a Etapa 3 precisa.

4. Como a etapa funciona

O código da Etapa 2 fica numa pasta própria (etapa2/), separada do coletor da Etapa 1, para facilitar a manutenção. Ela só lê o que a coleta deixou no corpus e não altera nada da Etapa 1. São dois scripts curtos:

Script	Entrada	O que faz	Saída
extrair.py	PDFs do corpus (raw/)	Converte cada PDF com o Docling; sem OCR por padrão, com OCR só se o texto sair ilegível. Pode ser interrompido e retomado.	markdown/<hash>.md + extracao.jsonl (páginas, tempo, OCR, erros)
limpar.py	Markdown do Docling + .txt do NTRS	Aplica a mesma limpeza mínima às duas origens e monta um índice único.	texto/<hash>.txt + texto/indice.jsonl

Cada documento é identificado pelo *hash* SHA-256 do arquivo, o mesmo usado na Etapa 1. Assim qualquer texto pode ser rastreado de volta ao PDF e à página de origem. O indice.jsonl é a entrada da Etapa 3: uma linha por documento com fonte, título, origem do texto (Docling, Docling com OCR ou .txt da NASA) e contagens.

5. Decisões tomadas e evidências

5.1 OCR desligado por padrão

Na configuração padrão o Docling aplica OCR em todas as páginas. No primeiro teste, um relatório da NASA de 118 páginas **passou de 25 minutos sem terminar**. Como os PDFs do corpus já têm texto digital, o OCR foi desligado: o mesmo documento foi convertido em **157 segundos**.

5.2 OCR só para documentos ilegíveis

Um dos PDFs do teste usa uma fonte com codificação quebrada: tanto o .txt da NASA quanto o Docling sem OCR devolveram apenas símbolos. Para esses casos o script mede quantas palavras reais há por mil caracteres (texto normal fica acima de 100; o documento quebrado ficou abaixo de 2). Abaixo de 30, o documento é convertido de novo com OCR. Assim o custo do OCR só é pago onde ele é necessário.

Na primeira versão a contagem incluía os espaços e traços das tabelas em Markdown. Um relatório de 3 páginas feito quase só de tabelas numéricas foi classificado como ilegível e passou por OCR à toa (28 minutos). A regra foi corrigida para contar só caracteres de conteúdo, e o documento voltou a ser convertido sem OCR. Limitação conhecida: em texto corrompido que sai como letras soltas (e não como símbolos) a regra pode não detectar o problema.

5.3 NTRS: PDF com Docling ou o .txt da NASA?

A ideia inicial era usar o .txt do NTRS sem processamento, pela preocupação de que converter os PDFs fosse lento demais. A decisão foi tomada com um teste: os mesmos 5 documentos do NTRS foram processados nas duas formas.

Documento (hash)	Páginas	Seções no Docling	Linhas de nº de página no .txt	Linhas repetidas (cabeçalhos) .txt / Docling
f9a46c88…	118	67	867	2213 / 106
f46e6953…	32	38	56	777 / 4
4074a915…	10	21	37	10 / 13
fa1c09af…	7	36	7	0 / 0
00cb731e…	46	—	36	ilegível nos dois (fonte quebrada)

- O volume de texto é praticamente o mesmo nas duas formas — o Docling não perde conteúdo.
- O .txt não tem nenhuma marcação de seção e muitas vezes quebra frases em uma palavra por linha; o Docling devolve os títulos numerados (ex.: ## 2.2.3. The Operational Immediate Decision-Making Situation).
- O .txt carrega muito mais ruído de layout (números de página, cabeçalhos repetidos).
- Custo medido no NTRS: 1.7 s por página em CPU. Os 152 PDFs do NTRS somam 3.829 páginas: cerca de 1,7 h de processamento.

Decisão (por enquanto): o NTRS continua usando o .txt da NASA, e o Docling roda só nas outras fontes. A comparação mostra que o Docling entrega texto mais estruturado também no NTRS, a um custo de cerca de 1,7 h; **converter os PDFs do NTRS fica como decisão pendente**, a ser discutida com as orientadoras conforme a necessidade da Etapa 3. Se aprovada, basta incluir o NTRS no script e rodá-lo de novo — o que já foi convertido é reaproveitado.

5.4 Limpeza mínima

O projeto previa um pré-processamento com expressões regulares. Ele foi mantido no mínimo, porque o Docling já remove a maior parte do ruído. A mesma limpeza vale para as duas origens:

- remover marcadores de imagem e linhas que contêm só um número de página;
- remover cabeçalhos e rodapés de página: linhas de 15 ou mais caracteres repetidas 10 ou mais vezes (ex.: Revision: B Document No: EVA-EXP-0042, repetida 174 vezes). O limite de 10 foi escolhido depois de verificar que, com 4, linhas legítimas de tabela também eram removidas;
- juntar linhas em branco repetidas. Títulos de seção e tabelas nunca são removidos.

6. Resultado

Nas fontes além do NTRS foram processados **43 PDFs (2317 páginas)**, com **0 erro(s)** e **0 documento(s)** que precisaram de OCR. Somando os documentos do NTRS disponíveis só em texto, a Etapa 2 entrega **108 textos** para a Etapa 3.

Fonte	PDFs	Páginas	s/página (média)
rosap	31	1636	7.1
faa	5	260	1.4
govuk	5	209	2.3
rosap_crawl	2	212	3.7
Total	**43**	**2317**	**5.7**

3 documento(s) ficaram fora da média de tempo: a conversão deles atravessou um período em que o computador estava suspenso ou incluiu o carregamento inicial dos modelos do Docling, e o tempo registrado não reflete o custo real de conversão.

Origem do texto	Documentos
.txt da NASA (NTRS)	65
Docling (sem OCR)	43
Ainda ilegíveis após o processamento	0

7. Limitações e próximos passos

- Os textos do NTRS vêm do .txt da NASA, sem marcação de seção. Os 152 PDFs do NTRS já baixados ficam fora do índice até a decisão da seção 5.3 (nem o PDF nem o .txt deles entram nesta rodada); a alternativa barata é baixar o .txt desses documentos.
- Em documentos com menos de 10 páginas, cabeçalhos repetidos podem permanecer no texto (ruído pequeno, escolhido para não remover conteúdo).
- Arquivos que não são PDF (2 apresentações .pptx e uma página do CORDIS) ficaram fora desta etapa.
- Próximo passo do projeto: **Etapa 3**, filtragem por palavras-chave do domínio (*Mission Concept*, *Operational Scenario*, *System Operational Description*) sobre texto/indice.jsonl.

Referências

Auer, C. et al. *Docling Technical Report*. arXiv:2408.09869, 2024.

READoc: A Unified Benchmark for Realistic Document Structured Extraction. arXiv:2409.05137.

Meuschke, N. et al. *A Benchmark of PDF Information Extraction Tools Using a Multi-task and Multi-domain Evaluation Framework for Academic Documents*. iConference, 2023.

hraju115. *pdf-extraction-benchmark* — 8 extratores locais em 27 documentos. github.com/hraju115/pdf-extraction-benchmark.